Raport projektowy
Uczenie się ze wzmocnieniem

Igor Paśko

2026/2027

Spis treści

1 Informacje podstawowe **2**

2 Temat i cel projektu **2**
2.1 Opis problemu . . . 2
2.2 Cel agenta . . . 2
2.3 Uzasadnienie zastosowania uczenia się ze wzmocnieniem . . . 2

3 Formalizacja problemu RL/MDP **2**
3.1 Agent i środowisko . . . 2
3.2 Stan lub obserwacja . . . 3
3.3 Akcje . . . 3
3.4 Funkcja nagrody . . . 3
3.5 Warunki zakończenia epizodu . . . 3
3.6 Założenia i ograniczenia środowiska . . . 4

4 Implementacja **4**
4.1 Struktura repozytorium . . . 4
4.2 Środowisko . . . 4
4.3 Agent bazowy . . . 4
4.4 Agent uczący się . . . 4

5 Plan eksperymentów **4**

6 Wyniki **5**

7 Analiza i wnioski **5**

8 Instrukcja uruchomienia **6**

9 Wsparcie AI **6**

10 Literatura **6**

1 Informacje podstawowe

Element	Informacja
Imię i nazwisko	Igor Paśko
Numer albumu	177137
Kierunek/specjalność	3EF-DI/AI
Tytuł projektu	Sterowanie agentem w grze unikania pocisków
Link do repozytorium	https://github.com/Igor-przinf/RL-bullet-dodge
Data oddania	Do uzupełnienia

2 Temat i cel projektu

2.1 Opis problemu

Rozpatrywanym problemem jest sterowanie obiektem (agentem) na dwuwymiarowej planszy w czasie rzeczywistym, którego głównym celem jest unikanie nadciągających z różnych kierunków pocisków (przeszkód) i przetrwanie jak najdłuższego czasu.

2.2 Cel agenta

Celem agenta jest opanowanie polityki ruchu, która pozwala mu unikać kolizji z pociskami przez maksymalny czas trwania epizodu. Działanie agenta uznaje się za skuteczne, gdy w procesie uczenia średni czas przeżycia oraz liczba unikniętych pocisków systematycznie rosną w stosunku do agenta bazowego.

2.3 Uzasadnienie zastosowania uczenia się ze wzmocnieniem

Zastosowanie uczenia się ze wzmocnieniem (RL) w tym problemie jest w pełni uzasadnione ze względu na sekwencyjny charakter podejmowanych decyzji:

- Agent podejmuje decyzje (ruch w określonym kierunku) w każdym kroku czasowym, co bezpośrednio wpływa na jego pozycję na planszy.
- Decyzje podjęte w danej chwili determinują przyszły stan środowiska oraz dostępną przestrzeń do manewru unikowego przed kolejnymi pociskami.
- Istotny jest wynik długoterminowy (całkowity czas przeżycia w epizodzie), a nie tylko natychmiastowa nagroda za pojedynczy unik.
- Problem nie ma charakteru statycznej klasyfikacji, lecz wymaga dynamicznej adaptacji strategii w interakcji ze zmieniającym się otoczeniem.

3 Formalizacja problemu RL/MDP

3.1 Agent i środowisko

Agentem jest obiekt poruszający się po dwuwymiarowej planszy. Środowisko generuje pociski pojawiające się na krawędziach ekranu, które przemieszczają się z określoną prędkością.

W pojedynczym kroku epizodu agent wykonuje akcję ruchu, środowisko aktualizuje pozycje pocisków, sprawdza kolizje i zwraca nowy stan oraz nagrodę.

3.2 Stan lub obserwacja

Wektor stanu w kroku czasowym t opisuje pozycję agenta oraz najbliższe pociski:

Składowa stanu/obserwacji	Znaczenie
x_a, y_a	Współrzędne pozycji agenta na planszy
$\Delta x_i, \Delta y_i$	Wektor względnej odległości do i-tego pocisku
v_{xi}, v_{yi}	Składowe prędkości i-tego pocisku

3.3 Akcje

Agent dysponuje dyskretną przestrzenią akcji pozwalającą na sterowanie na płaszczyźnie:

Akcja	Opis
0	Brak ruchu (pozostanie w miejscu)
1	Ruch w górę
2	Ruch w dół
3	Ruch w lewo
4	Ruch w prawo

3.4 Funkcja nagrody

Nagroda motywuje agenta do przetrwania i unikania zagrożeń:

$$r_t = \begin{cases} -100 & \text{kolizja z pociskiem (koniec epizodu),} \\ +1.0 & \text{za każdy przetrwany krok czasowy,} \\ -0.1 & \text{kara za zbliżenie się do krawędzi planszy.} \end{cases} \tag{1}$$

W tej sekcji wyjaśniono przyjęte założenia:

- Agent otrzymuje nagrodę dodatnią (+1.0) za każdy krok, w którym nie doszło do kolizji, co premiuje długie przeżycie.
- Kara (-100) jest nakładana natychmiastowo przy kolizji z pociskiem, co kończy epizod.
- Występuje niewielka kara za krawędzie, aby zapobiec utknięciu agenta w rogu planszy.

3.5 Warunki zakończenia epizodu

Epizod kończy się w przypadku:

1. Kolizji agenta z dowolnym pociskiem (porażka).
2. Osiągnięcia maksymalnego limitu kroków w epizodzie, np. $T_{max} = 1000$ (sukces).

3.6 Założenia i ograniczenia środowiska

Środowisko zakłada uproszczoną fizykę 2D (ruch prostoliniowy pocisków, dyskretne kroki czasowe). Pomięto zaawansowane efekty wizualne czy rotację pocisków, skupiając się wyłącznie na relacjach przestrzennych i decyzjach unikowych.

4 Implementacja

4.1 Struktura repozytorium

Projekt będzie opierał się na czystej strukturze katalogów przechowującej kod środowiska, skrypty trenujące oraz raport w LaTeX-u:

```
repozytorium/
|-- src/
|   |-- environment.py
|   |-- agent.py
|   `-- main.py
|-- experiments/
|-- report/
|-- results/
`-- README.md
```

4.2 Środowisko

Środowisko zostanie zaimplementowane w języku Python z wykorzystaniem biblioteki `Pygame` lub jako dedykowana klasa kompatybilna z interfejsem `Gymnasium`. Posiadać będzie funkcję `reset()` inicjalizującą pozycję gracza i listę pocisków oraz funkcję `step(action)`, która wykonuje ruch, aktualizuje pozycje pocisków, wykrywa kolizje i zwraca krotkę `(next_state, reward, done, info)`.

4.3 Agent bazowy

Jako punkt odniesienia (baseline) zostanie zaimplementowany agent losowy (*Random Agent*), który w każdym kroku wybiera akcję losowo z rozkładu jednostajnego. Posłuży on do wykazania, że algorytm uczenia ze wzmocnieniem faktycznie uczy się efektywnej polityki unikania.

4.4 Agent uczący się

Należy opisać zastosowany algorytm RL lub DRL, jego parametry oraz sposób implementacji. W przypadku Q-tab należy opisać reprezentację tablicy wartości. W przypadku DRL należy opisać wejścia modelu, wyjścia modelu, architekturę oraz sposób uczenia.

5 Plan eksperymentów

Należy opisać eksperymenty zaplanowane w celu oceny działania agenta.

Eksperyment	Co jest zmieniane?	Co jest mierzone?
E1	Do uzupełnienia	Do uzupełnienia
E2	Do uzupełnienia	Do uzupełnienia
E3	Do uzupełnienia	Do uzupełnienia

W tej sekcji należy wskazać:

- liczbę epizodów uczenia,
- liczbę powtórzeń eksperymentu albo uzasadnienie braku powtórzeń,
- parametry uczenia,
- metryki oceny,
- warianty środowiska, map lub funkcji nagrody,
- sposób porównania z agentem bazowym.

6 Wyniki

W tej sekcji należy przedstawić wyniki eksperymentów. Wyniki powinny być pokazane w postaci tabel, wykresów lub czytelnych zestawień.

Wariant	Średni zwrot	Skuteczność	Długość epizodu
Agent bazowy	Do uzupełnienia	Do uzupełnienia	Do uzupełnienia
Agent RL/DRL	Do uzupełnienia	Do uzupełnienia	Do uzupełnienia

Miejsce na wykres procesu uczenia

Rysunek 1: Przykładowy wykres procesu uczenia agenta.

7 Analiza i wnioski

Należy zinterpretować wyniki. W tej części należy odpowiedzieć m.in. na pytania:

- Czy agent uczący się działa lepiej niż agent bazowy?
- Jak zmieniało się zachowanie agenta w trakcie uczenia?
- Które elementy środowiska były najtrudniejsze?
- Czy funkcja nagrody prowadziła do oczekiwanego zachowania?
- Czy wystąpiły przypadki niepożądanego zachowania agenta?
- Jakie są najważniejsze ograniczenia rozwiązania?

8 Instrukcja uruchomienia

Należy opisać sposób uruchomienia projektu od czystego repozytorium. Przykładowo:

```
git clone https://github.com/...
cd nazwa-repozytorium
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
python src/main.py
```

Należy również wskazać, jak odtworzyć eksperymenty oraz gdzie zapisywane są wyniki.

9 Wsparcie AI

W tej sekcji należy obowiązkowo opisać wykorzystanie narzędzi sztucznej inteligencji. Jeżeli student nie korzystał z takich narzędzi, należy wpisać jednoznaczną informację, że nie korzystano ze wsparcia AI.

Data	Narzędzie/model	Cel użycia	Transkrypt / link / zakres
Do uzupełnienia	Do uzupełnienia	Do uzupełnienia	Do uzupełnienia
Do uzupełnienia	Do uzupełnienia	Do uzupełnienia	Do uzupełnienia

Należy zapisać transkrypty rozmów z modelami AI wraz z datą oraz nazwą modelu. Jeżeli rozmowa odbywała się poza narzędziami programistycznymi, należy dodatkowo udostępnić całą rozmowę poprzez link, o ile użyte narzędzie umożliwia takie udostępnienie.

Student powinien także wyjaśnić, które elementy wygenerowane lub zasugerowane przez AI zostały samodzielnie sprawdzone, zmodyfikowane albo odrzucone.

10 Literatura

W tej sekcji należy wskazać wykorzystane źródła: książki, artykuły naukowe, dokumentację bibliotek, materiały wykładowe oraz inne źródła użyte podczas pracy nad projektem.

Literatura

[1] R. S. Sutton, A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.